

Diagnóstico de cáncer de mama

Hito 2 · Modelamiento predictivo

Luis Jara · Hernán Leiva · Víctor Mardones · Juan Garcés

Diplomado en Ciencia de Datos

Septiembre de 2026

Del Hito 1 al Hito 2: cambia la pregunta

Hito 1 – pregunta exploratoria

¿Qué características morfológicas se diferencian entre tumores benignos y malignos, y cuáles repiten la misma señal?

Hito 2 – pregunta predictiva

¿Podemos predecir el diagnóstico de una muestra nueva, y con qué conjunto de variables se logra el mejor equilibrio entre desempeño y simplicidad?

#	Pregunta	Comparación
1	¿Superan las variables morfológicas a una clasificación trivial?	referencia 0.500
2	¿Las variables <code>worst</code> aportan sobre las <code>mean</code> ?	conjunto A vs. B
3	¿Las variables se justifican el modelo completo?	conjunto B vs. C
4	¿Qué familia de modelo conviene?	lineal vs. árbol vs. ensamble

Las cuatro se responden con validación cruzada dentro del entrenamiento, no con el test.

569 observaciones · 30 variables numéricas · 1 variable objetivo (*diagnosis*)

Estructura: 10 características × 3 resúmenes

Cada imagen aporta *_mean* (comportamiento típico), *_se* (variabilidad entre núcleos) y *_worst* (los núcleos más extremos). Esa estructura define los conjuntos que compararemos.

Clases

357 benignos (62.7 %) y 212 malignos (37.3 %).

Predecir siempre “benigno” acierta el 62.7 %
sin aprender nada: el *accuracy* simple no basta.

Calidad


Sin valores nulos ni duplicados. Se eliminan *id* y la columna vacía del archivo: conservar el identificador permitiría al modelo aprender del número de ficha en lugar de la morfología.

Conclusiones del Hito 1

- ▶ Las mayores diferencias aparecen en puntos cóncavos, perímetro, radio, área, concavidad y compacidad.
- ▶ Radio, perímetro y área forman un bloque fuertemente correlacionado.
- ▶ Los resúmenes `worst` separan mejor que las medias.
- ▶ El análisis descriptivo no mide desempeño predictivo: eso es el Hito 2.

Hipótesis que el Hito 2 pone a prueba

Si las `worst` separan mejor, un modelo que las incluya debería predecir mejor que uno construido solo con medias. El Hito 2 pone a prueba esa hipótesis con los conjuntos A, B y C.



Candados contra la filtración

- ▶ El test no participa en ninguna decisión.
- ▶ La estandarización se reajusta dentro de cada pliegue de validación.
- ▶ Los hiperparámetros se eligen solo con train + CV.

Por qué la estandarización va dentro

Calcular medias y desviaciones con el train completo antes de la validación cruzada usaría también las filas que harán de validación. Reajustarlas en cada pliegue evita esa filtración.

Conjuntos de variables

Conj.	Vars	Pregunta
A mean	10	base
B mean+worst	20	¿aportan worst?
C completo	30	¿aportan se?

Los define la estructura del dataset, no los datos: por eso no introducen sesgo.

Modelos (tres familias distintas)

Modelo	Por qué está
SVM lineal	frontera lineal; coeficientes legibles
Árbol de decisión	reglas y umbrales; se puede dibujar
Random Forest	ensamble; corrige el sobreajuste del árbol

Comparación justa

Los 9 candidatos usan el mismo train de 455 casos, los mismos 5 pliegues estratificados, las mismas grillas de hiperparámetros de la Práctica 5 y la misma métrica de selección.

Clase positiva: maligno

	Predice B	Predice M
Real B	TN	FP
Real M	FN	TP

FP: exámenes adicionales y angustia.


FN: un cáncer que no se detecta.

Qué reportamos y por qué

- ▶ **Balanced accuracy** = $\frac{\text{Sens} + \text{Esp}}{2}$: métrica de *selección*. No premia acertar la clase mayoritaria.
- ▶ **Sensibilidad y FN absolutos**: el error caro.
- ▶ **ROC-AUC**: desempeño en todos los umbrales.
- ▶ **Accuracy**: se reporta, pero no decide.

Predecir siempre “benigno” da accuracy 0.627 y balanced accuracy 0.500, sin detectar ningún tumor maligno.

Selección por validación cruzada




Patrón general

El conjunto A es el más débil con SVM y random forest. B y C quedan al mismo nivel. El árbol es el más bajo justo donde los otros mejoran: no aprovecha las worst.

Nada de esto vio el test

Los nueve valores son promedios sobre los 5 pliegues de validación, calculados únicamente con las 455 muestras de entrenamiento.

Los nueve candidatos con sus barras de error



Pregunta 2: sí aportan

De A a B el SVM sube de 0.928 a 0.967, un salto mayor que las barras de error. Las variables *worst* añaden información que las medias no tienen.

Pregunta 3: no hay evidencia

De B a C las barras se superponen por completo (0.967 vs. 0.961 en SVM; 0.965 en ambos para el bosque). Las se no justifican el modelo de 30 variables.

Criterio, fijado de antemano

1. Mayor balanced accuracy media en CV.
2. Si la diferencia es menor que la desviación entre pliegues, gana el de mayor sensibilidad.
3. Si persiste el empate, gana el más simple.

Resultado

B: mean+worst (20) + SVM lineal


Hiperparámetro elegido por GridSearchCV: $C = 0.1$

Desempeño en validación cruzada

Métrica	Valor
Balanced accuracy	0.967 ± 0.018
Sensibilidad (M)	0.947
ROC-AUC	0.991

Interpretación

La selección se hizo sin mirar el test, lo que evita quedarse con el candidato que ganó por suerte en una partición particular.




Test reservado: 114 muestras

Métrica	Valor
Accuracy	0.991
Balanced accuracy	0.988
Sensibilidad (M)	0.976
Especificidad	1.000
Precision (M)	1.000
ROC-AUC	0.997

En casos concretos

72 benignos correctos, 41 malignos correctos, **1 falso negativo** y ningún falso positivo. En CV el modelo daba 0.967: el test no lo contradice.


Mismo conjunto B: cómo se equivoca cada familia



Comparación descriptiva, no criterio de selección

La elección ya quedó fijada por validación cruzada; estas matrices solo describen el tipo de error de cada familia. El SVM deja 1 maligno sin detectar, el bosque 4 y el árbol 5, que además es el único que genera falsos positivos.

Curvas ROC sobre el conjunto seleccionado



Qué agrega respecto de la matriz

La matriz de confusión evalúa un único punto de corte. La ROC recorre todos los umbrales posibles y grafica sensibilidad contra tasa de falsos positivos.

Lectura

SVM lineal 0.997 y random forest 0.994 son prácticamente indistinguibles en capacidad de ordenamiento; el árbol (0.954) queda claramente por debajo, coherente con lo que muestran sus matrices.

- ▶ Las variables `worst` aportan información predictiva clara sobre las variables `mean`; agregar las variables se no produjo una mejora evidente.
- ▶ El mejor candidato fue **SVM lineal + mean+worst (20)**, seleccionado exclusivamente mediante validación cruzada dentro del entrenamiento.
- ▶ En validación cruzada obtuvo $BA = 0.967 \pm 0.018$; en el test reservado alcanzó $BA = 0.988$, sensibilidad = 0.976 y ROC-AUC = 0.997.
- ▶ En 114 casos de test produjo **1 falso negativo y 0 falsos positivos**.
- ▶ Random Forest mostró una capacidad de discriminación muy cercana al SVM, mientras que el árbol de decisión tuvo un desempeño menor.

Del diseño

- ▶ El test tiene 114 casos: el tamaño de la muestra acota la precisión de las estimaciones finales.
- ▶ Conjunto de referencia, no validación clínica externa.
- ▶ Sin validación sobre otra base de datos.

De la interpretación

- ▶ Predictores muy correlacionados: los coeficientes no son importancia causal.
- ▶ El umbral por defecto es una convención, no una recomendación clínica.
- ▶ El modelo estima asociaciones predictivas, no relaciones causales.

Trabajo futuro

Validación externa con otra cohorte, estudio del umbral orientado a sensibilidad y revisión de los casos cercanos a la frontera de decisión.

Gracias

Preguntas y discusión

Diagnóstico de cáncer de mama · Hito 2

Conjunto	Modelo	Bal. acc. CV	Hiperparámetros elegidos
A: mean (10)	SVM lineal	0.928 ± 0.014	$C = 1$
A: mean (10)	Árbol de decisión	0.940 ± 0.015	profundidad 3, mín. 3 por hoja
A: mean (10)	Random Forest	0.942 ± 0.024	25 árboles, sin límite
B: mean+worst (20)	SVM lineal	0.967 ± 0.018	$C = 0.1$
B: mean+worst (20)	Árbol de decisión	0.934 ± 0.023	sin límite, mín. 3 por hoja
B: mean+worst (20)	Random Forest	0.965 ± 0.025	125 árboles, profundidad 6
C: completo (30)	SVM lineal	0.961 ± 0.017	$C = 1$
C: completo (30)	Árbol de decisión	0.929 ± 0.025	sin límite, mín. 3 por hoja
C: completo (30)	Random Forest	0.965 ± 0.023	125 árboles, profundidad 6

Media y desviación sobre los 5 pliegues de validación, calculadas solo con las 455 muestras de entrenamiento.

Por qué no compite en la selección

Sus cuatro variables se eligieron en el Hito 1 mirando las 569 filas, incluidas las que hoy forman el test. Incluirlo entre los candidatos le daría una ventaja indebida frente a A, B y C, cuyos conjuntos se definen solo por la estructura del dataset.

Desempeño (solo descriptivo)

4 variables + SVM lineal: CV 0.962 ± 0.013 con $C = 1$, frente a 0.967 ± 0.018 del candidato seleccionado. En test: bal. acc. 0.945, con 4 FN y 1 FP.


Con cuatro variables se conserva casi todo, pero suben los falsos negativos.

Verificación de la selección

Repitiendo el procedimiento del Hito 1 ($|d|$ de Cohen más descarte por $|\rho| \geq 0.90$) usando **solo las 455 filas de entrenamiento**, se obtienen las **mismas cuatro variables**. La selección no dependía de haber visto el test.

Pregunta	Respuesta breve
¿Cómo eligieron el modelo?	Por balanced accuracy media en validación cruzada, usando solo las 455 muestras de entrenamiento.
¿Usaron el test para decidir?	No. Se usa una sola vez, con el candidato ya congelado.
¿Por qué un <i>pipeline</i> ?	Para que el escalador se reajuste dentro de cada pliegue y no filtre información entre ellos.
¿Por qué no accuracy?	El 62.7 % de los casos es benigno: predecir siempre “benigno” ya da 0.627.
¿Esa diferencia es significativa?	Las barras de error son la desviación entre pliegues; si se superponen, no hay evidencia.
¿Y la regresión logística?	No forma parte del contenido del curso; el modelo lineal utilizado es el SVM lineal.

Anexo: qué variables usa el candidato seleccionado




Coherencia con el Hito 1

Las variables de mayor peso se relacionan con tamaño, perímetro, radio, área y puntos cóncavos, sobre todo en su versión worst: las mismas que el análisis exploratorio identificó como más discriminantes.

Precaución

Varias de estas variables están altamente correlacionadas, de modo que el modelo puede repartir el peso entre ellas. Indica qué señales usa, no importancia causal.

Anexo: dos métodos, las mismas variables



Por qué se comparan

El random forest estima la importancia contando cuántas veces cada variable fue escogida como relevante por los árboles. El SVM lineal la expresa como el peso de cada coeficiente. Son criterios independientes.

Coinciden

Cuatro de las cinco primeras son las mismas (en naranja las comunes al top 10), y `radius_worst` encabeza ambas listas. La lectura no depende del modelo elegido.