

Diagnóstico de cáncer de mama

Modelamiento predictivo y evaluación del Hito 2

Preinforme v02

Luis Jara, Hernán Leiva, Víctor Mardones y Juan Garcés

Agosto de 2026

Abstract

Este documento presenta la versión actualizada del Hito 2 del proyecto de diagnóstico de cáncer de mama. A partir de las 30 características morfométricas estudiadas en el Hito 1, se formula una tarea de clasificación binaria supervisada para distinguir tumores benignos y malignos. Se comparan tres algoritmos desarrollados en las clases del diplomado: Support Vector Machine (SVM), Decision Tree y Random Forest. La comparación se realiza mediante una partición estratificada de entrenamiento y test, manteniendo el conjunto de test fuera del proceso de selección, y utilizando validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento para ajustar los hiperparámetros. La clase maligna se define como positiva debido a la importancia de los falsos negativos. Random Forest obtuvo la mayor *balanced accuracy* media en validación cruzada y fue seleccionado antes de examinar el test. En el conjunto de test reservado alcanzó una exactitud de 0.974, un *recall* para malignos de 0.929 y clasificó correctamente 39 de los 42 tumores malignos. Estos resultados corresponden a una evaluación predictiva sobre este conjunto de datos y no constituyen una validación clínica externa.

1 Introducción

El Hito 1 del proyecto estuvo orientado al análisis exploratorio del conjunto de datos: se estudiaron distribuciones, diferencias entre diagnósticos y relaciones entre las características morfométricas. El Hito 2 responde una pregunta distinta: si esas características contienen información suficiente para predecir el diagnóstico de una muestra que no fue utilizada durante el entrenamiento del modelo.

La tarea se formula como un problema de clasificación binaria supervisada. Se comparan tres modelos desarrollados explícitamente en la unidad de clasificación del diplomado: Support Vector Machine (SVM), Decision Tree y Random Forest [2]. El objetivo no es construir el sistema más complejo posible, sino establecer una comparación reproducible, sencilla de explicar y coherente con los conceptos de entrenamiento, validación, test y generalización estudiados en clases [1, 2].

2 Datos y síntesis del Hito 1

El conjunto de datos corresponde al *Breast Cancer Wisconsin (Diagnostic)* dataset [3, 4]. Cada observación describe una muestra obtenida mediante aspiración con aguja fina y contiene características numéricas calculadas a partir de núcleos celulares.

Después de la auditoría estructural utilizada en el proyecto, el conjunto queda compuesto por 569 observaciones, una variable objetivo (**diagnosis**), un identificador (**id**) y 30 predictores numéricos. La limpieza inicial solamente eliminó una columna vacía generada durante la lectura del archivo; no se eliminaron filas, no se imputaron datos, no se estandarizaron variables y no se realizó selección de predictores.

La variable **diagnosis** contiene 357 tumores benignos y 212 malignos. Las características describen diez propiedades morfométricas: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. Cada propiedad aparece mediante tres resúmenes: **mean**, **se** y **worst**.

El Hito 1 mostró que las diferencias más importantes entre diagnósticos aparecen en variables relacionadas con tamaño y forma, especialmente puntos cóncavos, perímetro, radio, área, concavidad y compacidad. También se observó una correlación elevada entre varias variables de tamaño, por ejemplo radio, perímetro y área. Las cuatro variables utilizadas para resumir visualmente esos resultados fueron seleccionadas con fines exploratorios y comunicacionales; no se demostró que constituyeran el conjunto predictivo óptimo. Por esta razón, en el Hito 2 se mantienen disponibles los 30 predictores.

3 Formulación de la tarea predictiva

Sea $\mathbf{x} \in \mathbb{R}^{30}$ el vector de características morfométricas de una muestra. La variable objetivo se codifica como

$$y = \begin{cases} 0, & \text{tumor benigno (B),} \\ 1, & \text{tumor maligno (M).} \end{cases}$$

Por tanto, maligno se define explícitamente como la clase positiva. Esta convención es importante para interpretar la matriz de confusión: un falso negativo (FN) corresponde a un tumor realmente maligno clasificado como benigno. Dentro de este problema, este es el tipo de error que requiere mayor atención.

La finalidad del modelo es predecir la etiqueta B o M para observaciones no utilizadas durante su entrenamiento. El objetivo del ejercicio es evaluar capacidad de generalización dentro de este conjunto de referencia; no se pretende sustituir una decisión clínica ni establecer una herramienta diagnóstica validada externamente.

4 Modelos de clasificación

4.1 Support Vector Machine

Support Vector Machine busca una frontera de decisión que separe las clases maximizando el margen entre ellas [2]. En este trabajo se utiliza una SVM lineal. El hiperparámetro C controla el compromiso entre mantener un margen amplio y penalizar observaciones mal clasificadas.

Las variables poseen escalas muy diferentes. Por ejemplo, el área toma valores numéricos mucho mayores que otras características como concavidad o dimensión fractal. Por ello, antes de ajustar la SVM se estandarizan los predictores. Esta transformación se incorpora dentro de un *pipeline*, de modo que la media y la desviación estándar de cada predictor se calculan únicamente con los datos disponibles en cada conjunto de entrenamiento. De esta forma se evita utilizar información de validación o test durante el preprocesamiento.

4.2 Decision Tree

Un árbol de decisión divide sucesivamente el espacio de características para construir subconjuntos cada vez más puros [2]. En este análisis se usa la impureza de Gini como criterio de división. La profundidad máxima del árbol se ajusta mediante validación cruzada, ya que un árbol demasiado profundo puede adaptarse excesivamente a los datos de entrenamiento y perder capacidad de generalización.

A diferencia de SVM, un árbol de decisión no depende de la escala relativa de las variables para definir sus puntos de corte, por lo que no se aplica estandarización.

4.3 Random Forest

Random Forest combina múltiples árboles de decisión. Cada árbol se entrena sobre una muestra obtenida mediante *bootstrap* y utiliza subconjuntos aleatorios de atributos, de modo que los árboles no aprendan exactamente las mismas divisiones [2]. La predicción final resulta de combinar las predicciones individuales del conjunto.

En la implementación utilizada se mantiene el criterio de Gini y se ajustan mediante validación cruzada el número de árboles y la profundidad máxima. Tampoco se aplica estandarización.

5 Metodología de entrenamiento y validación

La separación entre entrenamiento, validación y test sigue el principio de generalización desarrollado en clases: el entrenamiento permite aprender los parámetros del modelo, la validación permite seleccionar hiperparámetros y el test se reserva para la evaluación final [1, 2].

5.1 Partición de los datos

Se realizó una única partición estratificada y reproducible con semilla 42:

$$569 = 455 \text{ observaciones de entrenamiento} + 114 \text{ observaciones de test.}$$

La composición fue:

Table 1: Distribución de clases en las particiones de entrenamiento y test.

Conjunto	Benigno	Maligno	Total
Entrenamiento	285	170	455
Test	72	42	114

La estratificación mantiene aproximadamente la proporción original de benignos y malignos en ambas particiones. El conjunto de test no participa en el ajuste de hiperparámetros ni en la selección del modelo.

5.2 Validación cruzada

Sobre las 455 observaciones de entrenamiento se aplica validación cruzada estratificada de cinco pliegues (*Stratified 5-Fold*). Los tres clasificadores utilizan exactamente las mismas divisiones, permitiendo compararlos bajo las mismas observaciones de entrenamiento y validación.

La búsqueda de hiperparámetros fue deliberadamente acotada:

Table 2: Hiperparámetros evaluados mediante validación cruzada.

Modelo	Valores evaluados
SVM lineal	$C \in \{0.1, 1, 10\}$
Decision Tree	$\text{max_depth} \in \{3, 5, 7, \text{None}\}$
Random Forest	$\text{n_estimators} \in \{100, 300, 500\};$ $\text{max_depth} \in \{5, 10, \text{None}\}$

La métrica utilizada para seleccionar los hiperparámetros y el modelo fue la *balanced accuracy*, definida como el promedio entre sensibilidad y especificidad. Se utiliza como criterio complementario porque las clases no están perfectamente balanceadas. Sin embargo, la interpretación de los

resultados se realiza principalmente mediante las métricas de clasificación estudiadas en clase: matriz de confusión, exactitud, precisión, tasa de verdaderos positivos y tasa de falsos positivos.

6 Métricas de evaluación

Para la clase maligna como positiva se definen:

- verdadero positivo (TP): maligno clasificado como maligno;
- falso negativo (FN): maligno clasificado como benigno;
- verdadero negativo (TN): benigno clasificado como benigno;
- falso positivo (FP): benigno clasificado como maligno.

Las métricas principales son [2]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \text{TPR} = \frac{TP}{TP + FN},$$

$$\text{FPR} = \frac{FP}{FP + TN}.$$

También se utiliza la especificidad,

$$\text{Specificity} = \frac{TN}{TN + FP} = 1 - \text{FPR},$$

y la *balanced accuracy*,

$$\text{Balanced accuracy} = \frac{\text{TPR} + \text{Specificity}}{2}.$$

La curva ROC representa la relación entre TPR y FPR al modificar el umbral de clasificación. El área bajo la curva (ROC-AUC) se utiliza como resumen de la capacidad del modelo para ordenar observaciones malignas por encima de benignas. La matriz de confusión, en cambio, muestra los errores concretos obtenidos con la regla de decisión del clasificador.

7 Resultados

7.1 Comparación mediante validación cruzada

La Tabla 3 resume el rendimiento de los hiperparámetros seleccionados para cada modelo. Estos resultados provienen exclusivamente del conjunto de entrenamiento.

Table 3: Resultados medios de validación cruzada estratificada de cinco pliegues.

Modelo	B. Acc.	Accuracy	Recall M	ROC-AUC
SVM lineal	0.961 ± 0.017	0.965 ± 0.011	0.947	0.994
Decision Tree	0.917 ± 0.038	0.923 ± 0.033	0.894	0.917
Random Forest	0.963 ± 0.024	0.967 ± 0.021	0.947	0.988

Los hiperparámetros seleccionados fueron $C = 1$ para SVM, una profundidad máxima de 7 para Decision Tree y 100 árboles con profundidad máxima de 5 para Random Forest.




Figure 1: Comparación de la *balanced accuracy* de SVM, Decision Tree y Random Forest mediante validación cruzada estratificada de cinco pliegues realizada exclusivamente sobre el conjunto de entrenamiento. Las barras de error representan la desviación estándar entre pliegues.

Random Forest obtuvo la mayor *balanced accuracy* media, con 0.963, seguido muy de cerca por SVM con 0.961. La diferencia entre ambos es pequeña en comparación con la variación observada entre pliegues, por lo que no debe interpretarse como evidencia de una superioridad amplia de Random Forest. No obstante, dado que el criterio de selección fue definido previamente como la mayor *balanced accuracy* media, Random Forest quedó seleccionado como modelo principal antes de examinar el conjunto de test. Decision Tree presentó un rendimiento menor y una dispersión mayor.

7.2 Evaluación sobre el conjunto de test

Una vez finalizada la selección mediante validación cruzada, se evaluaron los modelos sobre las mismas 114 observaciones del conjunto de test reservado. Estos resultados se muestran con fines de evaluación y comparación; el rendimiento del test no se utilizó para cambiar el modelo seleccionado.

Table 4: Rendimiento sobre el conjunto de test reservado. M corresponde a la clase positiva (maligno).

Modelo	Accuracy	Precision M	Recall M	FPR	ROC-AUC	FN
SVM lineal	0.965	1.000	0.905	0.000	0.991	4
Decision Tree	0.939	0.949	0.881	0.028	0.922	5
Random Forest	0.974	1.000	0.929	0.000	0.995	3

Random Forest clasificó correctamente 111 de las 114 observaciones del test. De los 42 tumores malignos, 39 fueron identificados correctamente y 3 fueron clasificados como benignos.

Los 72 tumores benignos fueron clasificados correctamente, por lo que en esta partición no se produjeron falsos positivos.




Figure 2: Matriz de confusión de Random Forest sobre el conjunto de test reservado. El modelo clasificó correctamente 72 tumores benignos y 39 malignos. Los tres errores corresponden a falsos negativos: tumores malignos clasificados como benignos.

La ausencia de falsos positivos implica una precisión de 1.000 para la clase maligna en esta partición. Sin embargo, el *recall* de 0.929 muestra que el modelo no detectó todos los casos malignos. Esta distinción es importante: una precisión elevada no elimina la necesidad de analizar los falsos negativos.

7.3 Curvas ROC




Figure 3: Curvas ROC de los tres clasificadores calculadas sobre el mismo conjunto de test reservado. El eje vertical corresponde a la tasa de verdaderos positivos (TPR) y el eje horizontal a la tasa de falsos positivos (FPR). La diagonal representa una referencia sin capacidad discriminativa, con $AUC=0.5$.

SVM y Random Forest muestran curvas próximas al extremo superior izquierdo y valores ROC-AUC de 0.991 y 0.995, respectivamente. Decision Tree obtiene un ROC-AUC menor, 0.922. La curva ROC resume el comportamiento para distintos umbrales, mientras que la matriz de confusión muestra los errores concretos producidos por la decisión final del clasificador.

8 Discusión

Los resultados muestran que las 30 características morfométricas contienen suficiente información para obtener una separación elevada entre tumores benignos y malignos en este conjunto de datos. Los tres modelos superan el 0.88 de *recall* para la clase maligna en el test, aunque existen diferencias en estabilidad y número de errores.

SVM y Random Forest fueron los modelos más competitivos durante la validación cruzada. Random Forest alcanzó la mayor *balanced accuracy* media y fue seleccionado mediante el criterio establecido antes de utilizar el test. La diferencia con SVM es pequeña, por lo que la conclusión adecuada no es que Random Forest sea universalmente superior, sino que fue el modelo seleccionado dentro de este diseño experimental y presentó además el mejor rendimiento en el test reservado.

El comportamiento de Decision Tree es coherente con la mayor sensibilidad de un árbol individual a la estructura particular de los datos. Random Forest combina múltiples árboles y permite que errores individuales sean compensados por el conjunto, que es precisamente la motivación del método discutida en clases [2].

Desde la perspectiva del problema, los falsos negativos siguen siendo el resultado más importante. Random Forest produjo tres FN en el test. Por ello, una accuracy elevada no debe interpretarse

como ausencia de errores relevantes. La comparación entre accuracy, recall, FPR y matriz de confusión permite describir con mayor precisión el comportamiento del clasificador.

9 Limitaciones

- El conjunto contiene 569 observaciones y el test reservado solamente 114; por tanto, pequeñas diferencias en el número de errores pueden modificar las métricas de forma apreciable.
- El análisis utiliza una sola partición externa train/test, aunque la selección interna se estabiliza mediante validación cruzada estratificada.
- Los resultados corresponden a un conjunto de referencia y no constituyen validación clínica externa.
- Las 30 variables se conservaron porque el Hito 1 no estableció un criterio predictivo para eliminarlas. La alta correlación entre algunas características sigue siendo parte de la estructura del conjunto de datos.
- La elección de hiperparámetros fue deliberadamente acotada para mantener el análisis alineado con los contenidos del diplomado. No se realizó una búsqueda exhaustiva orientada a maximizar el rendimiento.
- El objetivo es evaluar clasificación y generalización; los resultados no establecen relaciones causales entre características morfométricas y malignidad.

10 Conclusiones

El Hito 2 transformó las conclusiones exploratorias del Hito 1 en una tarea de clasificación binaria supervisada. Se compararon SVM, Decision Tree y Random Forest utilizando los mismos 30 predictores y exactamente las mismas particiones de validación.

La selección de hiperparámetros se realizó únicamente con el conjunto de entrenamiento mediante validación cruzada estratificada de cinco pliegues. El test se mantuvo fuera de este proceso. Random Forest obtuvo la mayor *balanced accuracy* media en validación cruzada (0.963) y fue seleccionado como modelo principal antes de examinar el test.

En el conjunto de test reservado, Random Forest alcanzó una accuracy de 0.974, un *recall* para malignos de 0.929 y un ROC-AUC de 0.995. Clasificó correctamente 39 de los 42 tumores malignos y los 72 tumores benignos. Los tres errores observados fueron falsos negativos, por lo que este tipo de error debe permanecer explícitamente presente en la interpretación de los resultados.

En conjunto, el análisis proporciona una comparación reproducible y directamente relacionada con los métodos de clasificación estudiados en el diplomado, manteniendo una separación clara entre entrenamiento, selección mediante validación y evaluación final.

A Matrices de confusión de los modelos comparados

Las matrices de confusión de SVM y Decision Tree se conservan como material complementario para documentar la comparación completa y para apoyar la presentación oral.




Figure 4: Matriz de confusión de SVM lineal sobre el conjunto de test reservado.




Figure 5: Matriz de confusión de Decision Tree sobre el conjunto de test reservado.

B Variables utilizadas

Los tres clasificadores utilizan los mismos 30 predictores. El identificador `id` no participa en el modelamiento.

mean	se	worst
radius_mean	radius_se	radius_worst
texture_mean	texture_se	texture_worst
perimeter_mean	perimeter_se	perimeter_worst
area_mean	area_se	area_worst
smoothness_mean	smoothness_se	smoothness_worst
compactness_mean	compactness_se	compactness_worst
concavity_mean	concavity_se	concavity_worst
concave points_mean	concave points_se	concave points_worst
symmetry_mean	symmetry_se	symmetry_worst
fractal_dimension_mean	fractal_dimension_se	fractal_dimension_worst

References

- [1] Cabrera-Vives, G. *Fundamentos en Ciencia de Datos: Regresión*. Clase 6, Diplomado en Ciencia de Datos, Universidad de Concepción, 2026.
- [2] Cabrera-Vives, G. *Fundamentos en Ciencia de Datos: Clasificación*. Clase 7, Diplomado en Ciencia de Datos, Universidad de Concepción, 2026.
- [3] Wolberg, W., Street, W. N. y Mangasarian, O. L. *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository. DOI: 10.24432/C5DW2B.
- [4] Street, W. N., Wolberg, W. H. y Mangasarian, O. L. Nuclear Feature Extraction for Breast Tumor Diagnosis. *Proceedings of SPIE*, 1905, 861–870, 1993. DOI: 10.1117/12.148698.