

Diagnóstico de cáncer de mama

Análisis exploratorio, magnitud de las diferencias y selección de variables no redundantes

Diplomado en Ciencia de Datos

Luis Jara, Hernán Leiva, Victor Mardones y Juan Garces

Agosto de 2026

Abstract

Se realizó un análisis exploratorio de 569 muestras de tumores mamarios descritas mediante 30 variables numéricas extraídas de imágenes digitalizadas de aspiraciones con aguja fina. Las variables corresponden a diez características morfológicas de los núcleos celulares, resumidas mediante su media (**mean**), error estándar (**se**) y un resumen del extremo superior (**worst**). El análisis principal se concentró en las 20 variables **mean** y **worst**. Primero se cuantificó la separación entre tumores benignos y malignos mediante el tamaño de efecto de Cohen. Posteriormente se evaluó la redundancia mediante correlación de Spearman y se aplicó una selección secuencial que conserva las variables de mayor efecto cuando dos candidatas presentan información altamente correlacionada. El procedimiento conduce a cuatro variables representativas de dimensiones morfológicas diferentes: puntos cóncavos, tamaño, compacidad y textura. Este flujo permite construir una interpretación compacta del conjunto sin confundir una gran cantidad de columnas correlacionadas con evidencia independiente.

1 Introducción

El conjunto Breast Cancer Wisconsin (Diagnostic), en adelante WDBC, fue construido a partir de imágenes digitalizadas de aspiraciones con aguja fina de masas mamarias. Sobre los núcleos celulares segmentados se calcularon características de tamaño, forma y textura. El problema consiste en estudiar qué propiedades diferencian a los tumores benignos de los malignos y establecer una base razonada para una etapa posterior de clasificación.

El primer hito del proyecto corresponde a un análisis exploratorio. Por tanto, su objetivo no es presentar todavía un modelo predictivo definitivo, sino responder tres preguntas:

- 1) ¿Qué variables muestran las mayores diferencias entre tumores benignos y malignos?
- 2) ¿Cuáles de esas variables contienen información repetida?
- 3) ¿Qué conjunto pequeño de variables permite comunicar los patrones principales sin perder dimensiones morfológicas relevantes?

1.1 Pregunta de investigación

¿Qué características morfológicas presentan las mayores diferencias entre tumores benignos y malignos y cuáles de ellas aportan información complementaria, en lugar de repetir una misma señal altamente correlacionada?

1.2 Hipótesis de trabajo

Se plantea que los tumores malignos presentan núcleos de mayor tamaño y contornos más irregulares que los tumores benignos. En consecuencia, se espera que las variables relacionadas con puntos cóncavos, concavidad, compacidad, radio, perímetro y área presenten tamaños de efecto elevados. También se espera una redundancia importante entre radio, perímetro y área, debido a que las tres variables describen principalmente una misma dimensión geométrica.

2 Descripción de los datos

El archivo `data_breast_cancer.csv` contiene 569 observaciones. La variable objetivo es `diagnosis`:

Table 1: Distribución de la variable de diagnóstico.

Diagnóstico	Muestras	Porcentaje
Benigno (B)	357	62.7%
Maligno (M)	212	37.3%

Además de un identificador, cada muestra contiene 30 variables numéricas derivadas de diez características:

- 1) radio;
- 2) textura;
- 3) perímetro;
- 4) área;
- 5) suavidad;
- 6) compacidad;
- 7) concavidad;
- 8) puntos cóncavos;
- 9) simetría;
- 10) dimensión fractal.

2.1 Estructura `mean`, `se` y `worst`

Las definiciones de los sufijos provienen de la documentación del conjunto y del trabajo original de extracción de características:

- **mean**: media de la característica calculada sobre los núcleos aislados de la imagen;
- **se**: error estándar de esa característica dentro de la imagen;
- **worst**: resumen del extremo superior, implementado en la versión distribuida del conjunto como la media de los tres valores más altos de la característica.

Estas definiciones no fueron inferidas a partir de las distribuciones del CSV. La documentación establece el significado de cada columna; el análisis estadístico posterior determina cómo se comportan esas columnas en la muestra.

Las variables **se** no se utilizan como barras de error de las variables **mean** en la comparación entre diagnósticos. Cada columna **se** es un atributo independiente de una imagen y describe el error estándar calculado entre sus núcleos. En cambio, la incertidumbre de la media de **radius_mean**, por ejemplo, entre los 357 tumores benignos debe estimarse usando la variación de **radius_mean** entre esos tumores. Son dos niveles de análisis distintos.

3 Inspección inicial y calidad de los datos

La auditoría inicial consideró:

- dimensiones del archivo;
- tipos de datos;
- valores ausentes e infinitos;
- filas e identificadores duplicados;
- columnas vacías o constantes;
- distribución de la variable objetivo.

No se detectaron valores ausentes, infinitos, filas duplicadas ni identificadores repetidos. La única limpieza aplicada consistió en eliminar una columna completamente vacía. Por tanto, ninguna variable fue descartada por un problema de calidad.

4 Workflow del análisis exploratorio

El flujo de trabajo fue diseñado para separar dos problemas diferentes: *capacidad de separación* y *redundancia*. Una variable puede diferenciar claramente a los diagnósticos y, al mismo tiempo, repetir casi la misma información que otra.

4.1 Paso 1: conjunto de variables candidatas

El análisis principal utiliza las 20 columnas correspondientes a **mean** y **worst**:

$$10 \text{ características} \times 2 \text{ resúmenes} = 20 \text{ variables candidatas.}$$

Las diez variables **mean** describen el comportamiento promedio de cada característica. Las diez variables **worst** describen su extremo superior. Las columnas **se** se reservan para un análisis separado y, posteriormente, para evaluar si añaden información predictiva.

Esta decisión no implica que **se** sea una medición defectuosa, sino que cumple una función semántica diferente y no debe mezclarse con las medias como si fuera su incertidumbre grupal.

4.2 Paso 2: magnitud de la diferencia entre diagnósticos

Para cada candidata se calculó el tamaño de efecto de Cohen:

$$d = \frac{\bar{x}_M - \bar{x}_B}{s_{\text{combinada}}}, \quad (1)$$

donde $\bar{x}_M$ y $\bar{x}_B$ son las medias de los grupos maligno y benigno, y $s_{\text{combinada}}$ es la desviación estándar combinada. Un valor positivo indica valores mayores en tumores malignos.

Cohen d permite comparar variables expresadas en escalas muy diferentes. Su función en este trabajo no es determinar un diagnóstico individual, sino ordenar las variables según la magnitud de su separación univariada.

La incertidumbre de d se estimó mediante remuestreo bootstrap estratificado, manteniendo por separado las muestras benignas y malignas.

4.3 Paso 3: ranking pareado de mean y worst

Las 20 variables se ordenaron según $|d|$. Sin embargo, para conservar la estructura semántica, las versiones **mean** y **worst** de una misma característica se muestran juntas y con el mismo color.




Figure 1: Ranking de tamaños de efecto para las 20 variables **mean** y **worst**. Las dos versiones de una misma característica aparecen juntas y comparten color. El tramado identifica las variables **worst**.

Esta figura permite responder dos preguntas simultáneas: qué características presentan mayor separación y si el resumen **worst** aumenta o disminuye esa separación respecto de **mean**. El

resultado no permite concluir que **worst** sea siempre superior; por ejemplo, la concavidad media presenta un efecto mayor que su versión extrema.

4.4 Paso 4: correlación y detección de redundancia

Las variables se evaluaron mediante correlación de Spearman. Esta medida se prefirió porque varias relaciones son monótonas pero no estrictamente lineales y porque las distribuciones presentan asimetrías y valores extremos.

Se consideró redundancia fuerte cuando:

$$|\rho_{\text{Spearman}}| \geq 0.90. \quad (2)$$

El umbral es un criterio exploratorio, no una ley universal. Su propósito es detectar variables que ordenan las muestras de manera prácticamente equivalente.

4.5 Paso 5: selección secuencial

La selección se aplicó de manera reproducible:

- 1) ordenar las 20 candidatas por $|d|$;
- 2) seleccionar la variable de mayor efecto;
- 3) comparar la siguiente candidata con todas las variables ya seleccionadas;
- 4) si $|\rho| \geq 0.90$, considerarla redundante y conservar la variable que apareció antes en el ranking, es decir, la de mayor $|d|$;
- 5) continuar hasta obtener cuatro variables no fuertemente redundantes.




Figure 2: Correlación de Spearman entre las variables examinadas durante la ruta de selección. Las variables seleccionadas aparecen destacadas. El mapa permite identificar los bloques que repiten una misma señal morfológica.

El mapa de correlaciones no determina por sí solo qué variable es más importante. Su función es complementar el ranking de Cohen y evitar que un conjunto final contenga varias columnas que expresan prácticamente la misma información.

4.6 Paso 6: inspección de las distribuciones

Las cuatro variables seleccionadas se inspeccionaron mediante histogramas separados por diagnóstico. Para cada grupo se añadieron:

- una curva gaussiana de referencia construida con la media y la desviación estándar observadas;
- una línea para la media;
- una línea para la mediana.

La curva gaussiana es únicamente una referencia visual y no constituye una prueba de normalidad. Por ello, la tabla descriptiva conserva también la mediana, el rango intercuartílico y la asimetría.

Distribuciones de las cuatro variables seleccionadas




Figure 3: Distribuciones de las cuatro variables seleccionadas. Los elementos azules corresponden a tumores benignos y los naranjos a tumores malignos. Las curvas gaussianas se muestran como referencias descriptivas.

5 Resultados

5.1 Separación univariada

Las variables con mayor tamaño de efecto corresponden principalmente a puntos cóncavos y a medidas de tamaño. Los primeros lugares del ranking fueron:

Table 2: Principales variables según la magnitud de Cohen d .

Variable	Cohen d
<code>concave points_worst</code>	2.693
<code>perimeter_worst</code>	2.598
<code>concave points_mean</code>	2.545
<code>radius_worst</code>	2.544
<code>perimeter_mean</code>	2.290
<code>area_worst</code>	2.230
<code>radius_mean</code>	2.205
<code>area_mean</code>	2.076
<code>concavity_mean</code>	2.003
<code>concavity_worst</code>	1.812

En todas estas variables los tumores malignos presentan valores medios mayores. El patrón central es consistente con núcleos de mayor tamaño y contornos más cóncavos o irregulares.

5.2 Ruta de selección

La primera variable seleccionada fue `concave points_worst`, por presentar el mayor $|d|$. Su versión `mean` fue descartada de la selección comunicacional debido a su elevada correlación con `concave points_worst`.

La segunda variable seleccionada fue `perimeter_worst`. Las variables `radius_worst`, `perimeter_mean`, `area_worst`, `radius_mean` y `area_mean` fueron consideradas redundantes respecto de esta señal de tamaño. No se interpretan como variables inútiles; simplemente repiten una dimensión ya representada.

Las variables `concavity_mean` y `concavity_worst` también presentaron una relación elevada con la señal de puntos cóncavos y no fueron incorporadas al conjunto final bajo el umbral adoptado.

La tercera variable seleccionada fue `compactness_mean`, que mantiene un efecto grande sin superar el umbral de redundancia respecto de las seleccionadas previamente. La cuarta fue `texture_worst`, cuyo efecto es menor, pero presenta correlaciones suficientemente bajas con las tres anteriores y aporta una dimensión complementaria de textura.

Table 3: Variables seleccionadas mediante magnitud de efecto y control de redundancia.

Orden	Variable	Cohen d	Interpretación principal
1	<code>concave points_worst</code>	2.693	Presencia extrema de puntos cóncavos; mayor separación univariada.
2	<code>perimeter_worst</code>	2.598	Representante del bloque robusto de tamaño: radio, perímetro y área.
3	<code>compactness_mean</code>	1.535	Relación entre perímetro y área; aporta una descripción adicional de la irregularidad de la forma.
4	<code>texture_worst</code>	1.061	Resumen extremo de la heterogeneidad de intensidades; aporta una dimensión menos correlacionada con tamaño y puntos cóncavos.

5.3 Interpretación del mapa de correlaciones

El bloque más intenso corresponde a las variables de tamaño. Radio, perímetro y área, tanto en sus versiones medias como extremas, presentan correlaciones muy elevadas. Considerarlas como hallazgos independientes produciría una sobreinterpretación de una misma señal geométrica.

También se observa una asociación fuerte entre medidas de concavidad, compacidad y puntos cóncavos. Sin embargo, este bloque es menos homogéneo que el de tamaño, por lo que no todas sus variables deben considerarse intercambiables.

La textura presenta correlaciones menores con los dos grandes bloques. Aunque su Cohen d es menor, puede añadir información complementaria. Este ejemplo muestra por qué la selección no debe basarse exclusivamente en escoger los cuatro valores más altos de d .

5.4 Lectura de las distribuciones

Las distribuciones de las variables seleccionadas muestran un desplazamiento general de los tumores malignos hacia valores mayores. Existe, sin embargo, una zona de solapamiento entre los diagnósticos. Por esta razón, ninguna variable individual constituye una regla perfecta de clasificación.

La cercanía o diferencia entre media y mediana permite evaluar visualmente la asimetría. Cuando ambas difieren y la cola derecha es pronunciada, la curva gaussiana debe interpretarse con cautela. La media y la desviación estándar se complementan con mediana y rango intercuartílico para evitar una descripción basada únicamente en supuestos de normalidad.

6 Criterios de inclusión y exclusión

Las variables no fueron excluidas por falta de calidad. La omisión de una variable en las figuras principales responde a uno de los siguientes criterios:

- 1) **redundancia fuerte:** presenta $|\rho| \geq 0.90$ con una variable de mayor efecto ya seleccionada;

- 2) **señal univariada menor:** posee un efecto inferior al de las candidatas seleccionadas;
- 3) **representación comunicacional:** su patrón ya se encuentra cubierto por otra variable semánticamente más clara o de mayor magnitud.

Esta selección tiene un propósito exploratorio y comunicacional. No constituye una selección definitiva para el futuro modelo. En la etapa predictiva, cualquier procedimiento de selección deberá aplicarse exclusivamente sobre el conjunto de entrenamiento o dentro de la validación cruzada para evitar filtración de información.

7 Discusión

El análisis confirma que la magnitud de una diferencia y la independencia de la información son conceptos distintos. Los cuatro primeros lugares de un ranking pueden pertenecer a solo una o dos dimensiones morfológicas. El uso de Spearman después de Cohen d evita presentar varias expresiones del tamaño como si fueran descubrimientos separados.

El término **worst** tampoco debe interpretarse como una medición defectuosa. Representa el extremo superior de la distribución de una característica dentro de la imagen. Su tamaño de efecto elevado muestra que los núcleos con valores altos contienen una señal diagnóstica importante, pero no demuestra automáticamente que sean más confiables que las variables **mean**. La comparación pareada permite observar en qué características el extremo amplifica la diferencia y en cuáles la media es igualmente o más informativa.

Las columnas **se** se mantendrán disponibles para una etapa posterior. Su utilidad deberá comprobarse comparando, dentro de validación cruzada, modelos construidos con **mean**, **mean+se**, **mean+worst** y las 30 variables. Este análisis permitirá determinar si los resúmenes adicionales mejoran realmente la clasificación.

8 Conclusiones

- 1) El conjunto contiene 569 muestras y 30 variables numéricas sin problemas relevantes de calidad.
- 2) La comparación exploratoria principal se realizó sobre 20 variables: diez **mean** y diez **worst**. Las columnas **se** se reservaron como descriptores separados.
- 3) Las mayores diferencias entre diagnósticos se concentran en puntos cóncavos y tamaño nuclear.
- 4) Radio, perímetro y área forman un bloque altamente redundante. El perímetro extremo fue conservado como su representante debido a su mayor tamaño de efecto.
- 5) El procedimiento combinado de Cohen d y Spearman seleccionó cuatro variables: **concave points_worst**, **perimeter_worst**, **compactness_mean** y **texture_worst**.
- 6) Los tumores malignos presentan, en general, mayores valores de concavidad, tamaño, compacidad y textura extrema, aunque las distribuciones conservan cierto solapamiento.
- 7) El análisis exploratorio sustenta la hipótesis de que los tumores malignos poseen núcleos mayores y contornos más irregulares, y proporciona una base justificable para la futura etapa predictiva.

9 Próxima etapa

La etapa predictiva deberá comparar conjuntos de variables predefinidos y evaluarlos mediante validación cruzada. La selección de variables deberá realizarse dentro del proceso de entrenamiento. La evaluación no se basará únicamente en exactitud, sino también en sensibilidad para tumores malignos, especificidad, F1 y área bajo la curva ROC.

References

- [1] Wolberg, W., Street, W. N. y Mangasarian, O. L. *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository. DOI: 10.24432/C5DW2B.
- [2] Street, W. N., Wolberg, W. H. y Mangasarian, O. L. *Nuclear Feature Extraction for Breast Tumor Diagnosis*. Proceedings of SPIE, vol. 1905, pp. 861–870, 1993. DOI: 10.1117/12.148698.
- [3] Cohen, J. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, segunda edición, 1988.