

Proyectos Fundamentos en Ciencia de Datos

Para el proyecto semestral se deben considerar grupos de 3 a 4 personas.

Idealmente, cada grupo debe proponer un dataset a utilizar para el proyecto. Alternativamente, pueden escoger uno de los proyectos descritos en la próxima página (hacer click en el título del proyecto para acceder a los datos). Habrán dos hitos relacionados con los proyectos:

- **Hito 1:** Presentación oral de análisis exploratorio, la cual deberá contener una introducción explicando la pregunta o el problema a resolver y su relevancia, la descripción exacta de los datos a utilizar y el análisis exploratorio que sustente una hipótesis de investigación.

Fecha de presentación: viernes 14 de agosto a las 18:15 hrs.

Evaluación:

Introducción: 15%

Descripción de los datos: 15%

Análisis exploratorio: 15%

Presentación: 25%

Preguntas: 30%

- **Hito 2:** Presentación oral final, la cual, además del contenido de la entrega anterior, debe contener la descripción del(los) modelo(s) predictivo(s) utilizados, la metodología para ajustarlo, los resultados obtenidos y conclusión del trabajo.

Fecha de presentación: viernes 4 de septiembre a las 18:15 hrs.

Evaluación:

Introducción: 10%

Descripción de los datos y análisis exploratorio: 10%

Modelamiento: 15%

Resultados: 15%

Presentación: 20%

Preguntas: 30%

No se deberá entregar un informe escrito asociado al proyecto.

Proyecto 1

Predicción de calidad en planta de flotación minera

El objetivo es predecir el % de Silica (impureza) a partir de un conjunto de datos proveniente de una planta de flotación. Se dispone de 737.454 observaciones (marzo -septiembre 2017) para las cuales se reportan los siguientes atributos:

- Medidas de calidad del mineral de hierro justo antes de la planta de flotación (col. 2-3).
- Medidas al final del proceso de flotación (col. 4-8).
- Flujo de aire en proceso de flotación (col. 9-22).
- Medida final de calidad de mineral de hierro mediante laboratorio (col. 23-24).

Nota: La columna objetivo a predecir es la columna 24 que corresponde al % de Silica en el mineral de hierro concentrado.

Proyecto 2

Diagnóstico de cáncer de mama

El objetivo es clasificar un tumor en Maligno (M) o Benigno (B) a partir de un conjunto de datos que contiene características extraídas de la imagen digitalizada de una biopsia de bulto en mama. Se dispone de 569 muestras, 357 de ellas benignas y 212 malignas. Cada muestra posee una identificación (ID number), el diagnóstico (diagnosis) y 30 atributos relacionados a 10 características:

1. radius: media de las distancias desde el centro hacia puntos del perímetro.
2. texture: desviación estándar de las intensidades en escala de grises.
3. perimeter.
4. area.
5. smoothness: variación local de largo de los radios.
6. compactness: $\text{perimeter}^2 / \text{area} - 1.0$
7. concavity: severidad de secciones cóncavas en la delineación.
8. concave points: número de secciones cóncavas en la delineación.
9. symmetry.
10. fractal dimension: "coastline approximation" - 1

Proyecto 3

Predicción de valor de propiedades

El objetivo de este proyecto es utilizar valores de propiedades en Melbourne del 2016 para predecir el valor de las propiedades el 2017. Para esto, disponemos de un conjunto de datos de valores de propiedades con 21 distintos atributos:

1. Rooms: Número de habitaciones
2. Price: Precio en dólares
3. Method: Método de venta.
 - a. S - propiedad vendida

- b. SP - propiedad vendida con anterioridad
 - c. PI - propiedad pasada en
 - d. PN - vendida con anterioridad, precio no disponible
 - e. SN - vendida, precio no disponible
 - f. NB - sin oferta
 - g. VB - oferta del vendedor
 - h. W - retirada, previo a remate
 - i. SA - rematada
 - j. SS - rematada, precio no disponible
 - k. N/A - precio u oferta más alta no disponible
4. Type: Tipo
- a. br - habitaciones
 - b. h - casa
 - c. u - unidad, duplex
 - d. t - townhouse
 - e. dev site - sitio en desarrollo;
 - f. o res - otro residenciall.
5. SellerG: Agente de bienes raíces
6. Date: Fecha de venta
7. Distance: Distancia al centro financiero
8. Regionname: Región (West, North West, North, North east ...etc)
9. Propertycount: Número de propiedades existentes en el suburbio
10. Bedroom2 : Número de habitaciones (obtenidas usando scrapping de diferentes fuentes)
11. Bathroom: Número de baños
12. Car: Número de estacionamientos
13. Landsize: Tamaño del terreno
14. BuildingArea: Tamaño construido
15. CouncilArea: Zona del gobierno local

En este proyecto deberán usar las ventas de propiedades para entrenar un modelo predictivo con datos del 2016, y luego predecir y evaluar su modelo sobre las propiedades del año 2017.