

Predicción del valor de propiedades en Melbourne

Proyecto 3 · Hito 2 · Fundamentos de Ciencia de Datos

Entrenar con ventas 2016 ($n = 6.336$) → predecir y evaluar sobre 2017 ($n = 7.244$)

C. Abrigo · C. Herrera · K. Urbina

Toda cifra de este deck proviene de anclaje.json o de DashAI (dataset 22); ninguna se escribió a mano.

El problema: predecir 2017 con la data de 2016

Pregunta, hipótesis y protocolo de evaluación temporal.

Pregunta

¿Puede un modelo entrenado solo con transacciones de 2016 estimar precios de 2017 con error menor que una regla básica de mercado (mediana 2016)?

H1

Las relaciones entre características (habitaciones, tipo, ubicación) y precio observadas en 2016 se mantienen lo suficiente en 2017 para predecir mejor que la estimación básica.

H0

Esas relaciones no se mantienen: el modelo no supera a la mediana de 2016.

6.336

Train 2016 (46,7 %)

7.244

Test 2017 (53,3 %)

MAE 431.649 AUD

Regla básica a superar: predecir la mediana 2016 en 2017 (anclaje.cota)

- Test 2017 se usa una sola vez, al final.
- Selección de variables y preprocesamiento aprendidos solo con 2016.
- Mismo protocolo replicado en DashAI con split manual por índices (2016 → train, 2017 → test).

Datos: 13.580 ventas, 21 atributos, 2016-01-28 → 2017-09-23

housing_data.csv (snapshot Kaggle melb_data). SHA-256 verificado en anclaje.py.

13.580

ventas observadas

21

atributos originales

903.000

precio mediano (AUD)


1.075.684

precio medio (cola derecha)

Tipo	n	Mediana precio
casa (h)	9.449	1.080.000
casa pareada (t)	1.114	846.750
dúplex (u)	3.017	560.000

- Cobertura temporal: ene–dic 2016 (sin mar); feb–sep 2017 (hasta 2017-09-23). 2017 no es un año completo.
- 314 barrios, 8 regiones, 268 vendedores, 5 métodos de venta.
- Duplicados de fila completa: 0. Reventas que cruzan el corte: 36 propiedades (0.51 % de 2017).
- Target: Precio. Estructura: Habitaciones, Baños, Estacionamientos, Tamaño de terreno, Tipo. Espacial: Barrio, Distancia, Región, Latitud/Longitud. Comercial: Método, Vendedor, Fecha.


Nulos concentrados en tres columnas: fuera por nulos, no por falta de señal



- 99,5 % de las 13.256 celdas nulas están en BuildingArea, YearBuilt y CouncilArea.
- Los nulos crecen en 2017: CouncilArea 0.0 % → 18.9 %; BuildingArea 43.1 % → 51.3 %.
- Ceros sospechosos: 1.939 Landsize = 0 (14.3 %), 17 BuildingArea = 0, 6 Distance = 0. Se documentan, no se borran.
- Plausibilidad: YearBuilt mínimo 1196; 6 construcciones posteriores a la venta; Landsize máx. 433.014 m².
- Decisión: BuildingArea y YearBuilt salen del modelo POR NULOS (imputar ≈ mitad del dataset). No por falta de señal: YearBuilt–Precio = -0.262 es la 2.ª |r| en DashAI.

Señal en estructura y ubicación; ninguna |r| supera 0,5

Correlaciones = explorador de DashAI (Pearson, 8 columnas numéricas). Tipo no entra en Pearson: se lee por medianas.



6+ habitaciones: n = 86 (no se grafican). Fuera del heatmap DashAI: Bathroom, Bedroom2, Car, Type, Region. Habitaciones–Precio +0.497 es la más alta, no «fuerte».

2017 no es una muestra de 2016: 172 barrios nuevos = 29 % del test

Auditoría de cambio de composición (anclaje.no_vistos / composicion).

172

barrios de 2017 ausentes en 2016 (142 → 313)

29,1 %

de las filas de 2017 (2.109)

17.9 km

distancia mediana en barrios nuevos (vs 8.0 km)

755.000

mediana precio barrios nuevos (vs 999.000)

Indicador	2016	2017
Mediana precio	900.000	910.000
Distancia mediana (km)	8.8	10.5
% casas	65.8	72.9
% dúplex	25.7	19.1


- Deriva agregada de la mediana: 1.11 %; en barrios comparables: 11.0 %. Lo agregado esconde el cambio de composición.
- Decisión: no usar Barrio one-hot (fallaría en 29 % del test). Ubicación = Distancia + Latitud + Longitud (continuas) + Región.
- Preprocesamiento aprendido solo con 2016; categorías nuevas → ignoradas, no imputadas con 2017.
- Método y Tipo no presentan categorías nuevas en 2017.

Benchmark en DashAI: baseline → lineal → árbol → ensambles

DashAI dataset 24, sesión 8: split manual 2016 (train 90 % / validation 10 %) → test 2017 (100 %). Hiperparámetros por defecto.

Modelo	MAE 2017	RMSE 2017	R² 2017	R² train
Baseline mediana 2016	431.649	654.393	-0.080	—
Regresión lineal	297.317	457.460	0.472	0.626
Árbol de decisión	286.088	466.126	0.452	1.000
Random Forest	218.986	354.664	0.683	0.973
Gradient Boosting	212.760	338.848	0.710	0.821

- Variables (Hito 1): Habitaciones, Baños, Estacionamientos, Tamaño de terreno, Distancia, Latitud, Longitud, Cantidad de propiedades, Tipo, Método, Región.
- Fuera: BuildingArea y YearBuilt (nulos), CouncilArea (nulos + niveles nuevos), Barrio/Postcode (alta cardinalidad, 172 barrios nuevos). Habitaciones2 redundante con Habitaciones (notebook Hito 1).
- Criterio: menor MAE en 2017 con menor brecha train–test; el baseline fija la cota que H1 debe superar.



H1 se sostiene: los ensambles reducen el error frente a la mediana de 2016

Modelo del proyecto: Random Forest (decisión Hito 1). Gradient Boosting como alternativa.

49,3 %

reducción de MAE vs baseline (RF):
431.649 → 218.986

0,683

R^2 de Random Forest en 2017

1,36×

menor MAE que la regresión lineal (RF)

212.760

MAE de Gradient Boosting (R^2 0,710)

- Random Forest: MAE 218.986, RMSE 354.664, R^2 0.683 en 2017; R^2 train 0.973 (brecha +0.290).
- Gradient Boosting: MAE 212.760, R^2 0.710; R^2 train 0.821 (brecha +0.110).
- Regresión lineal: MAE 297.317, R^2 0.472 — la relación es no lineal.
- Cota trivial por tipo (mediana 2016 por Tipo): MAE 394.385 (−8.6 %); los ensambles la superan ampliamente.

- Qué se transfiere de 2016 a 2017: estructura + ubicación continua. Qué no: los 172 barrios nuevos (29,1 % del test) con precios y distancias distintas.
- Límite: 2017 cubre solo feb–sep 2017 (hasta 2017-09-23); el error típico (MAE $\approx$ 218.986 AUD, $\sim$ 24 % de la mediana 2017) debe declararse junto a cada predicción.
- Siguiendo paso: error desagregado por barrio nuevo/conocido y por tipo; comparar con el pipeline local del notebook.