



DIPLOMA EN
CIENCIA DE DATOS

Fundamentos de Bases de Datos y Algoritmos

CLASE #5

Ilse Gutiérrez Soto

Ingeniera Civil Informática
ILSEGUTIERREZ@UDEC.CL

Bases de Datos Multidimensionales Y Big Data

Aprendizajes del módulo

1. Especificar modelos de datos que permitan describir a alto nivel los requerimientos de persistencia de sistemas de análisis de datos
2. Implementar bases de datos que den respuesta a diversos requerimientos de almacenamiento, análisis y procesamiento de datos

Aprendizajes de la sesión

1. Conocer los usos y ventajas de los modelos de datos multidimensionales.
2. Diseñar modelos multidimensionales.
3. Conocer conceptos generales de bases de datos no estructuradas

Modelado Multidimensional

Recordemos

- OLAP

- Datos del negocio para Información
- Orientado al sujeto
- Actual + histórico
- Detallada + más resumida
- Estable

- OLTP

- Datos Operacionales
- Orientado a la aplicación
- Actual
- Detallada
- Cambia continuamente

Datawarehouse y Sistema DW

- Es un conjunto de datos orientados a temas, integrados, no volátiles e históricos, organizados para soportar un proceso de toma de decisiones.
- Sistema DW es un sistema informático capaz de ofrecer información para toma de decisiones, y cuya pieza principal es un Data Warehouse.


DW: Características

- Datos Orientados a Temas
 - Los datos se organizan en torno a los temas principales de la organización
- Datos integrados
 - Heterogeneidad de datos:
 - Diferentes áreas de la organización.
 - Diferentes tipos (tradicionales, geográfico, documentos).
 - Diferentes fuentes
 - Aspectos a resolver en la integración:
 - Unificación de conceptos.
 - Construcción del dato integrado a partir de los fuentes.
 - Disimilaridad esquemática y semántica

DW: Características

- Datos históricos:
 - Se deben manejar los datos con su referencia temporal.
 - El tiempo siempre es una dimensión relevante
- Datos no volátiles:
 - Una vez que los datos son estables, se pueden ingresar al DW
 - Los datos no se modifican, sólo se incorporan nuevos
 - Los datos deben ser lo suficientemente estables como para permitir análisis “largos” sin que cambien durante el mismo.
 - Esto se obtiene como consecuencia de:
 - La historización.
 - La planificación de la carga.

Componentes de un DW



Data Marts

- Son aplicaciones de análisis de datos en áreas precisas de negocios. Por ejemplo: Adquisiciones, Registro Curricular, Marketing, Producción.
- Toman sus datos del Data Warehouse.
- Priorizan la funciones de análisis de datos:
 - Interfaces a usuario.
 - Indicadores específicos al área de negocio.
- Normalmente basados en OLAP.

Proceso de Desarrollo de un DW


- Componentes a desarrollar:
 - Mecanismo de Adquisición de Datos
 - Almacenamiento del DW
 - Mecanismos de acceso para usuarios finales
- Fases
 - Etapa 1: Concepción de iniciativas.
 - Etapa 2: Definición de la infraestructura.
 - Etapa 3: Desarrollo de aplicaciones.

Datawarehouse

- Tipo/s de DBMS.
 - Relacional, Multidimensional, o ambos.
- Concepción del DW.
- Diseño e implementación de la carga.
- Administración del DW:
 - Cómo describir y documentar los datos ?
 - Qué información hay que monitorear ?
 - Cómo organizar y realizar la administración del DW ?
 - Mediante qué tipo de herramientas ?

DBMS para el Data Warehouse

- **DBMSs Relacionales:**
 - Solución "universal".
 - Soportan el grueso de las aplicaciones DW.
 - Dificultades para resolver eficientemente consultas dimensionales.
- **DBMSs Multi-Dimensionales:**
 - Representan los datos del problema en términos de dimensiones.
 - Estructuras de almacenamiento están diseñadas para optimizar consultas dimensionales.



Enfoques de Diseño Conceptual


- **Análisis desde requerimientos:**
 - Los requerimientos son el universo de información.
 - Las bases fuente se relacionarán luego.
 - Aplicable cuando se tienen Bases Fuentes complejas. (Se analizan con los requerimientos en mente).
- **Análisis desde datos:**
 - Datos fuentes son el universo de información.
 - El DW se obtiene transformando las fuentes.
 - Aplicable cuando los requerimientos están poco claros.

Enfoques de Diseño Conceptual

- Enfoque MDA
 - Ortogonal a los enfoques previos
 - Se basa en la transformación de modelos, ya sea desde los requerimientos o los datos fuentes
 - Aún en desarrollo
- Objetivos de los MMD:
 - Representar los datos en forma cercana a la intuición del usuario.
 - Resolver problemas planteados en sistemas relacionales.

Características


- Se representan los datos como una matriz.
 - En los ejes están los criterios de análisis.
 - En los cruces están los valores a analizar.
 - A esta estructura se le llama Cubo o Hipercubo.



M O D E L O	Mini Van	6	5	4
	Coupe	3	5	5
	Sedan	4	3	2
		Blue	Red	White
		COLOR		


Características

- Agregando una 3a. dimensión:



Características

- Agregando una 4a. dimensión:



Estructuras básicas

- Los Cubos o Hipercubos constan de:
 - Dimensiones:
 - Criterios de análisis de los datos.
 - Macro-objetos del problema.
 - Variables independientes.
 - Ejes en el hipercubo.
 - Medidas
 - Valores o indicadores a analizar.
 - Datos asociados a relaciones entre los objetos del problema.
 - Variables dependientes.
 - Variables en la intersección de las dimensiones.

Estructuras básicas

- En el ejemplo anterior:
 - Dimensiones:
 - Modelo
 - Color
 - Vendedor
 - Fecha
 - Medida:
 - Cantidad Vendida

Dimensiones

- Jerarquías:
 - Los valores se organizan en jerarquías (categorías).
 - Por ejemplo: Dimensión: Vendedores




Medidas

- Propiedades:
 - Se ubican en la intersección de algunos valores de las dimensiones. Dado un valor para cada dimensión se puede determinar un valor para la medida.

Definición: Se llama **coordenada** a una tupla formada por un valor de cada dimensión.

Medidas



M O D E L O	Mini Van	6	5	4
	Coupe	3		5
	Sedan	4	3	2
		Blue	Red	White

COLOR



VENTAS("Mini Van", "Blue")=6

Cubos


- La realidad se modela como un conjunto de cubos.
 - Cada cubo, esta formado por:
 - Un conjunto de **Dimensiones** organizadas en **jerarquías**.
 - Un conjunto de **Medidas** asociadas a cada **coordenada**.
 - Es posible moverse en las jerarquías de las dimensiones y observar de esa forma, diferentes visiones de las medidas.

Ejemplo

■ Dimensiones




■ Medidas




Características de los modelos multidimensionales

- Permiten describir una realidad en términos de matrices multidimensionales (Cubos).
- Desde el punto de Vista del DW, se utilizan para describir Datamarts o el DW Completo.
- Las Dimensiones pueden tener una o más jerarquías.


Esquema Estrella (Star)




Esquema Copo de Nieve (Snowflake)



Esquema Copo de Nieve (Snowflake)



Esquema desnormalizado



Herramientas

Figure 1: Magic Quadrant for Analytics and Business Intelligence Platforms



Source: Gartner March (2023)

Actividad

- Modele el modelo multidimensional para el caso de estudio.
- Use la fuente de datos provista y defina medidas y dimensiones.

Big Data

Big Data

- Permiten manejar datos estructurados y no estructurados, por medio de algoritmos especialmente diseñados para gestionar grandes volúmenes de información.
- También mediante la toma de muestras significativas de esas grandes cantidades de datos, para lograr estadísticas importantes para los negocios.




Fuentes de datos para Big Data

Generalmente se catalogan las fuentes de **big data** en las siguientes categorías:

- Web y redes sociales
- Datos biométricos
- Machine-to-Machine
- Generados por humanos
- Grandes datos de transacciones

4V del Big Data



Datos Estructurados

- Con datos estructurados nos referimos a la información que se suele encontrar en la mayoría de bases de datos.
- Son archivos que se suelen organizar en filas y columnas con títulos, con estructuras fijas.
- Son datos que pueden ser ordenados y procesados fácilmente por todas las herramientas de minería de datos.

¿Qué son datos NO estructurados?

- Son datos que no tienen estructura interna identificable.
- Es un conglomerado masivo y desorganizado de varios objetos que no tienen valor hasta que se identifican y almacenan de manera organizada.



Tipos de Datos No Estructurados

- Correos electrónicos.
- Archivos de procesador de texto.
- Archivos PDF.
- Hojas de cálculo.
- Imágenes digitales.
- Vídeo.
- Audio.
- Publicaciones en redes sociales.

Análisis de estos tipos de datos

- Para trabajar con estos tipos de datos, requerimos técnicas especiales para extraer información y conocimiento de ellos.
 - Así es como para documentos o incluso publicaciones de redes sociales, se utilizan procesamiento del lenguaje natural.
 - En imágenes se puede utilizar técnicas como detección de imagen, reconocimiento facial e incluso interpretación de contextos.

Bases de datos NoSQL

- “Open Source Relational Database” de Carlo Strozzi en los 90, donde se consulta a través de scripts y no por medio de SQL.
- Las bases NoSQL son bautizadas así en 2009 y aunque el termino no es oficial, se refiere a bases
Open Source, Distribuidas y No Relacionales

Características

- No tienen esquemas o tablas.
- No permiten JOIN.
- No garantizan las propiedades ACID (Atomicidad, Consistencia/Integridad, Aislamiento y Durabilidad).
- Siguen el Modelo BASE
 - Basic Availability
 - Software State
 - Eventual consistency

Características

- Estructuras de datos simples.
- Proveen principalmente mecanismos de lectura y escritura.
- Apropriadas para big data.
- Redundancia de datos, dada la estructura distribuida que hace que los datos se guarden en varios servidores.

Beneficios


- **Flexibilidad:** ofrecen esquemas flexibles que permiten un desarrollo más rápido. El modelo de datos flexible hace que las bases de datos NoSQL sean ideales para datos semiestructurados y no estructurados.
- **Escalabilidad:** las bases de datos NoSQL generalmente están diseñadas para escalar usando clústeres distribuidos de hardware en lugar de escalar añadiendo servidores caros y sólidos. Algunos proveedores de la nube manejan estas operaciones fuera del alcance, como un servicio completamente administrado.
- **Alto rendimiento:** la base de datos NoSQL está optimizada para modelos de datos específicos (como documentos, clave-valor y gráficos) y patrones de acceso que permiten un mayor rendimiento que el intento de lograr una funcionalidad similar con bases de datos relacionales.
- **Altamente funcional:** las bases de datos NoSQL proporcionan API altamente funcionales y tipos de datos que están diseñados específicamente para cada uno de sus respectivos modelos de datos.

Bases de datos

- Modelos de datos que puede manejar
 - Clave-valor.
 - Documentos.
 - Orientados a columnas.
 - Grafos
 - Orientados a objetos

Tipos de Bases NoSQL

- **Almacenes de clave-valor:** son las bases de datos NoSQL más simples. Cada elemento de la base de datos se almacena como un nombre de atributo (o «clave»), junto con su valor. Ejemplos de almacenes de clave-valor son Riak y Berkeley DB. En algunos almacenes de clave-valor, como Redis, cada valor puede tener un tipo, como «entero», lo que le añade funcionalidad.



Key-Value

Tipos de Bases NoSQL

- **Bases de datos de documentos:** en estas bases de datos se empareja cada clave con una estructura de datos compleja que se denomina 'documento' (JSON – BSON) . Los documentos pueden contener muchos pares de clave-valor distintos, o pares de clave-matriz, o incluso documentos anidados.



Type	Alias
Double	"double"
String	"string"
Object	"object"
Array	"array"
Binary data	"binData"
Undefined	"undefined"
ObjectId	"objectId"
Boolean	"bool"
Date	"date"
32-bit integer	"int"
Timestamp	"timestamp"
64-bit integer	"long"
Decimal128	"decimal"

Tipos de Datos BSON

Tipos de Bases NoSQL


- **Bases de datos orientadas a columnas:** estas bases de datos, como Cassandra o HBase, permiten realizar consultas en grandes conjuntos de datos y almacenan los datos en columnas, en lugar de filas, Tienen un enfoque desnormalizado.



Column

Tipos de Bases NoSQL

- **Basadas en grafos:** se utilizan para almacenar información sobre redes de datos, como las conexiones sociales. Ejemplos de almacenes de grafos son Neo4J y Giraph.



Bases de datos NoSQL conocidas

Documentos	Grafo	Clave – Valor	Orientada a Objeto
<u>CouchDB</u> <u>MongoDB</u> <u>RavenDB</u> <u>Rhinos</u> <u>BaseX</u> <u>djondb</u> <u>eXist</u> <u>SimpleDB</u> <u>IBM Lotus Domino</u> <u>Terrastore</u>	<u>Neo4j</u> <u>DEX/Sparksee</u> <u>AllegroGraph</u> <u>OrientDB</u> <u>InfiniteGraph</u> <u>Sones GraphDB</u> <u>InfoGrid</u> <u>HyperGraphDB</u>	<u>Cassandra</u> <u>BigTable</u> <u>Dynamo</u> <u>Project Voldemort</u> <u>Riak</u> <u>Redis</u> <u>Oracle NoSQL</u>	<u>HBase</u> <u>BigTable</u> <u>LevelDB</u> <u>Hypertable</u>